# **Modeling**

## 1. Muat Data

- df = pd.read\_csv("processed\_kelulusan.csv")
- X = df tanpa kolom target "Lulus", y = df["Lulus"]
- Dua panggilan train\_test\_split:
  - Pertama: test\_size=0.3, stratify=y, random\_state=42 → menghasilkan X\_train, X\_temp dengan shapes yang tercetak: (7,5) untuk train, (1,5) untuk val (ternyata hasil akhir), (2,5) untuk test printed shapes (7,5) (1,5) (2,5).

## Interpretasi & catatan penting

- Dataset sangat kecil: total sampel = 7+1+2 = 10 (atau total 10). Ini sangat rentan overfitting dan membuat estimasi performa tidak stabil.
- Kamu memakai stratify=y bagus untuk menjaga proporsi kelas, tapi dengan sampel sedikit, setiap split bisa berisi sangat sedikit (0/1/2) contoh per kelas sehingga beberapa fold/partition jadi hanya berisi satu kelas.
- Akibatnya metrik seperti ROC-AUC atau metrik berbasis ranking bisa tidak terdefinisi jika test/val hanya mengandung satu kelas.

#### 2. Baseline Model & Pipeline

```
... Baseline (LogReg) F1(val): 1.0
precision recall f1-score support

1 1.000 1.000 1
accuracy 1.000 1
macro avg 1.000 1.000 1
weighted avg 1.000 1.000 1
```

- Membuat ColumnTransformer bernama pre untuk kolom numerik:
  - SimpleImputer(strategy="median") diikuti StandardScaler()
  - o remainder="drop"
- Pipeline pipe\_Ir = Pipeline([("pre", pre), ("clf", logreg)])
- logreg = LogisticRegression(max\_iter=1000, class\_weight="balanced", random\_state=42)
- Fit di X\_train, prediksi ke X\_val, lalu print F1 (macro) dan classification report.

## Interpretasi

- Kamu menerapkan preprocessing di dalam pipeline ini benar/baik: mencegah data leakage.
- class weight="balanced" berguna kalau kelas tidak seimbang.
- Ini adalah **baseline** yang sahih: simple, interpretable, dan diperlakukan adil dengan pipeline dan stratify.
- Baseline (LogReg) F1(val): 1.0
- classification\_report menunjukkan precision/recall/f1 = 1.000 untuk kelas yang ada di val;
   support = 1 (hanya 1 sample di val untuk kelas tersebut).

# Interpretasi & peringatan

- F1(val)=1.0 terdengar sempurna namun support di val hanya 1 contoh. Itu **tidak meyakinkan**: kinerja sempurna pada 1 contoh tidak berarti model generalizes.
- Karena dataset kecil, skor sempurna sangat mungkin tanda **overfitting** atau kebetulan split yang "mudah".

#### 3. Model Alternatif (Random Forest)

- RandomForestClassifier(n\_estimators=300, max\_features="sqrt", class\_weight="balanced", random\_state=42)
- Pipeline pipe\_rf = Pipeline([("pre", pre), ("clf", rf)])
- Fit dan prediksi pada X\_val, lalu print F1(val)

#### Hasil

• RandomForest F1(val): 1.0

# Interpretasi

- RandomForest juga mencapai F1=1.0 pada validation set yang sama konsisten dengan baseline, tetapi masih terpengaruh masalah sample kecil.
- Karena kedua model sempurna di val, selanjutnya dilakukan tuning/CV agar memilih model final secara lebih andal.

#### 4. Validasi Silang & Tuning Ringkas

```
F1(test): 1.0

precision recall fi-score support

0 1.000 1.000 1.000 2

accuracy 1.000 2

accuracy 1.000 2

weighted avg 1.000 1.000 1.000 2

confusion matrix (test):

[[2]]

RCC.AUC(test): nan

d.\Nachine learning\venv\lib\site-packages\sklearn\matrics\ classification.py:534: UserNarning: A single la warnings. warn(
d.\Nachine learning\venv\lib\site-packages\sklearn\matrics\ ranking.py:424: UndefinedMetricNarning: Only or warnings. warn(
d.\Nachine learning\venv\lib\site-packages\sklearn\matrics\ ranking.py:424: UndefinedMetricNarning: Only or warnings. warn(
d.\Nachine learning\venv\lib\site-packages\sklearn\matrics\ ranking.py:120: UndefinedMetricNarning: Only or warnings warn(
```

- final\_model = best\_rf (atau pipe\_lr jika dipilih)
- y\_test\_pred = final\_model.predict(X\_test)
- Print f1\_score(y\_test, y\_test\_pred, average="macro"), classification\_report, confusion\_matrix
- ROC-AUC: jika ada predict\_proba, coba y\_test\_proba = final\_model.predict\_proba(X\_test)[:,1] lalu roc\_auc\_score dan roc\_curve & savefig.

# Hasil (7.7):

- F1(test): 1.0
- classification report shows support=2 (test set only had 2 samples) and perfect metrics
- Confusion matrix printed as [[2]] (1x1 matrix -> only one class present in y test)
- ROC-AUC(test): nan and sklearn warnings:
  - o UserWarning: A single label...
  - UndefinedMetricWarning: Only one class present in y\_true. ROC AUC is not defined in that case.

## Penjelasan

- Test set sangat kecil dan **mungkin hanya berisi satu kelas** itulah kenapa confusion matrix adalah [[2]] dan ROC-AUC menjadi nan (tidak bisa dihitung ketika y\_test memiliki satu kelas saja).
- Skor F1=1.0 valid untuk test set tersebut, tapi karena test sangat kecil dan hanya satu kelas, nilai ini **tidak valid** sebagai indikator generalisasi.

# 5. Evaluasi Akhir (Test Set)

```
# Predikti label
yhat MODEL.predict(X)[0]

# Predikti probabilities (jika ada)
proba = None
if hasattr(MODEL, "predict_proba"):
    proba = None
if hasattr(MODEL, "predict_proba(X)[0, 1])

# Remailian hasil dalan format 2500
return jsonify(("prediction": int(yhat), "proba": proba))

except Exception as e:
    " lika ada error, kirimian pasan error dalam 2500
return jsonify(("error": str(e))), 480

if __name__ == "__msin__":
    app.run(port=5000)

# Predikti label
    yhat = MODEL.predict(X)[0]

# Predikti label
yhat = MODEL.predict(X)[0]

# Predikti label
proba = None
if hasattr(MODEL, predict_proba(X)[0, 1])
# Kembalisan hasil dalam format 2500
return jsonify(("prediction": int(yhat), "proba": proba))
except Exception as e:
    scept Exception as e:
    s
```

```
** Serving Flask app '__main__'

* Debug mode: off

WARNING: This is a development server. Do not use it in a production deployment. Use a production WSGI server instead.

* Running on <a href="http://127.0.0.1:5000">http://127.0.0.1:5000</a>

Press CTRL+C to quit

127.0.0.1 - - [22/Oct/2025 21:17:55] "GET / HTTP/1.1" 200 -
127.0.0.1 - - [22/Oct/2025 21:17:55] "GET /favicon.ico HTTP/1.1" 404 -
```

joblib.dump(final model, "model.pkl")

# Flask app:

- MODEL = joblib.load("model.pkl")
- Route / GET → message "Flask API is running!"
- Route /predict POST → ambil JSON body data = request.get\_json(force=True) lalu X = pd.DataFrame([data])
- yhat = MODEL.predict(X)[0]
- proba = None ; jika ada predict\_proba, ambil float(MODEL.predict\_proba(X)[0,1])
- return jsonify({"prediction": int(yhat), "proba": proba})